

УДК 004.932.4

ОБЗОР МЕТОДОВ УСЛОВНОЙ ГЕНЕРАЦИИ ИЗОБРАЖЕНИЙ НЕЙРОСЕТЕВЫМИ МОДЕЛЯМИ

Фисько Дмитрий Владимирович

магистрант кафедры информатики

Научный руководитель: **Сиротко Сергей Иванович**

кандидат физико-математических наук

Белорусский государственный университет

информатики и радиоэлектроники

Аннотация: Условные генеративные нейросетевые модели для генерации изображений высокого разрешения открывают возможности для создания качественно новых продуктовых решений. Условная генерация изображений на данный момент является темой активных исследований, при этом исследовательское сообщество сильно продвинулось в поисках методов генерации изображений. В статье рассматривается история развития условных генеративных методов, а также современные архитектуры условных генеративных нейросетевых моделей и методы их обучения.

Ключевые слова: Генерация изображений, условные генеративные нейросетевые модели.

OVERVIEW OF METHODS FOR CONDITIONAL IMAGE SYNTHESIS

Fisko Dmitry Vladimirovich

Sirotko Sergey Ivanovich

Abstract: Generative neural network models for generating high-resolution images open up opportunities for creating qualitatively new product solutions. Conditional image generation is currently a topic of active research, and this research community has made great strides in the search for image generation methods. In this article, we will trace the history of the development of conditional generative methods. We will also consider modern solutions for conditional generative neural network models and methods for their training.

Key words: Image generation, conditional generative neural network models.

Введение

Обзор современных методов для условной генерации изображений производился на основе анализа решений для генерации изображений на основе датасета ADE20K¹.

Image-to-Image Translation with Conditional Adversarial Networks²

Основополагающая научная работа, которая предложила использовать условные генеративные нейронные сети для решения задач преобразования изображения из одного домена в другой без необходимости адаптации архитектуры нейронной сети под новые домены. Инвариантность к смене домена достигается с помощью выучивания функции потерь прямо в ходе обучения нейронной сети. Нейронная сеть состоит из двух подсетей: генератора и дискриминатора. Генератор учится преобразовывать изображения из одного домена в другой с качеством приемлемого уровня для обмана дискриминатора. Дискриминатор учится отличать сгенерированное изображение от настоящего изображения из обучающей выборки. Генератор и дискриминатор обучаются поочередно на одном и том же батче обучающей выборки.

В данной работе не удалось получить генерацию качественных изображений размером большим 256×256 . При увеличении размера для генерации, обучение нейронной сети становилось очень нестабильным.

Photographic Image Synthesis with Cascaded Refinement Networks³

Авторами статьи было выдвинуто предположение, что состязательные нейронные сети слишком нестабильны при обучении и по этой причине стоит отойти от этой концепции. Было предложено для обучения генератора изображений отойти от использования концепции дискриминатора на минимизирование более стабильной функции потерь. При этом простая функция потерь не способна дать качественное изображение, например минимизация L1 loss приведёт к очень размытым нереалистичным изображениям. По этой причине, авторы продолжили идею использовать уже обученную нейронную сеть, чтобы именно она оценивала качество генерирующей нейронной сети. Использовать сумму L1 loss между различными уровнями активации обученной нейронной сети VGG19 для исходного изображения и сгенерированного. Слои на разных уровнях нейронной сети выучиваются определять различные уровни абстракции. Если на нижних уровнях нейронной сети сеть склонна обращать внимания на углы изображения, то на более высоких слоях, нейронная сеть начинает определять уже более высокоуровневые составные абстракции. Поэтому чтобы

сгенерированное изображение было качественным, необходимо в функции потерь использовать активации с разных уровней нейронной сети.

High-Resolution Image Synthesis and Semantic Manipulation with Conditional GANs⁴

В этой работе были значительно улучшены результаты работы Pix2Pix, при этом был опровергнут тезисы из работы CRN, о несостоятельности состязательных нейронных сетей для обучения генератора изображений высокого разрешения, из-за слишком большой нестабильности при обучении, и отсутствия высокой детализации в генерируемых изображениях.

Авторам статьи удалось добиться более лучших результатов по сравнению с предыдущими работами с помощью улучшения архитектуры генератора и дискриминатора, а также увеличением надёжности функции потерь. В своей работе авторы показали, что при использовании только одного perceptual loss для обучения генератора возникает ряд недостатков: эта функция потерь способна генерировать изображения высокого разрешения, но для них характерны недостаточное качество текстур и слабая детализация.

Semantic Image Synthesis with Spatially-Adaptive Normalization⁵

Нормализация как слой нейронной сети очень сильно повлиял на проектирование нейронных сетей. Нормализация позволила сделать более гладким пространство функции потерь, тем самым ускорив сходимость и улучшив стабильность обучения нейронных сетей. При этом в слое нормализации серьёзный недостаток: данный слой вымывает из ранее вычисленных слоёв часть знаний, что может значительно повлиять на качество генерируемого изображения. Чтобы предотвратить вымывание данных об структурных особенностях и стиле, полученном из предыдущих слоёв нейронной сети, авторы данной статьи предложили идею блока, подмешивающего исходные данные об структуре изображения. Данный блок выполняет привычную нормализацию, но затем на основе исходных данных выполняет процесс демодуляции нормализованных данных сегментации. Демодуляция происходит с помощью аффинных преобразований, параметры преобразований вычисляются на основе отмасштабированных данных о сегментации.

You Only Need Adversarial Supervision for Semantic Image Synthesis⁶

Повышение качества генерации изображений достигается через изменение архитектуры дискриминатора. Вместо обучения классификации изображений на настоящие и сгенерированные, дискриминатор обучается

задачи сегментации изображения. Дискриминатор классифицирует каждый пиксель входящего изображения, к какому из $N+1$ классов он принадлежит. Помимо N исходных классов сегментации, $N+1$ является классом сгенерированного пикселя. Дискриминатор старается определить, принадлежит ли каждый из пикселей к настоящему классу сегментации или этот пиксель сгенерированный. Данный дискриминатор обеспечивает попиксельно информацию при применении оптимизационного алгоритма, что в свою очередь обеспечивает лучшее качество генерируемых изображений и лучшее соответствие исходной карте сегментации из обучающей выборки. Улучшение обратной связи из дискриминатора за счёт внедрения новой архитектуры, позволило отказаться от использования perceptual loss.

Предложенный авторами метод позволил упростить архитектуру и процесс обучения нейронной сети для генерации изображений, при этом добиться более лучших показателей качества.

Вывод

Методы условной генерации изображений прошли через серию значительных эволюционных улучшений. Первый успех в генерации изображений был достигнут с помощью использования состязательной нейронной сети. Данная нейронная сеть давала изображения относительно хорошо качества, но при её обучении не удалось преодолеть барьер в разрешении изображения 256×256 . Процесс обучения данной сети был крайне неустойчив.

По причине нестабильного процесса обучения состязательных нейронных сетей, в последующих работах были высказаны предложения заменить использование архитектуры состязательных нейронных сетей, в которой функция потерь задана неявно, на более стабильную архитектуру, в которой функция потерь задана явно. В качестве такой функции потерь было предложено использовать L1 loss между слоями активаций предобученной нейронной сети на основе архитектуры VGG, так называемой perceptual loss.

Авторы следующих статей показали, что возможно обучить состязательную нейронную сеть для генерации изображений высокого разрешения, при этом улучшив метрики качества предыдущих работ. Ранее возникающая проблема с нестабильным процессом обучения была решена через добавление perceptual loss и её аналога на основе слоёв активаций дискриминатора.

Стабилизировав обучения состязательных нейронных сетей, исследователи сосредоточились на поисках наиболее эффективных архитектур подсетей. Исследователи заметили, что слои нормализации в значительной мере фильтруют информацию, переданную на вход генерирующей подсети. Чтобы решить эту проблему, был предложен подход с заменой обычной нормализации на условную нормализации, состоящей из двух стадий. На первой стадии выполняется обычная нормализация, на второй стадии выполняется денормализация с помощью параметров, вычисленных на основе исходных данных. Данный слой условной нормализации позволил в значительной мере упростить архитектуру генерирующей подсети.

Минус использования perceptual loss заключается в том, что нейронная сеть, используемая для вычисления данной функции потерь, обучалась на данных из другого домена, тем самым perceptual loss будет ограничивать вариативность при генерации изображений из другого домена. Чтобы убрать этот компонент из функции потерь, исследователи предложили увеличить мощность подсети дискриминатора, заменив целевую задачу классификации на задачу сегментации. Новый дискриминатор позволил получить более лучший отклик при обучении генератора и убрать использование компоненты perceptual loss из функции потерь.

Список литературы

1. Image-to-Image Translation on ADE20K Labels-to-Photos // Paperswithcode.com [Электронный ресурс]. – Режим доступа: <https://paperswithcode.com/sota/image-to-image-translation-on-ade20k-labels>
2. Image-to-Image Translation with Conditional Adversarial Networks // Arxiv.org [Электронный ресурс]. – Режим доступа: <https://arxiv.org/abs/1611.07004>
3. Photographic Image Synthesis with Cascaded Refinement Networks // Arxiv.org [Электронный ресурс]. – Режим доступа: <https://arxiv.org/abs/1707.09405>
4. High-Resolution Image Synthesis and Semantic Manipulation with Conditional GANs // Arxiv.org [Электронный ресурс]. – Режим доступа: <https://arxiv.org/abs/1711.11585>

5. Semantic Image Synthesis with Spatially-Adaptive Normalization // Paperswithcode.com [Электронный ресурс]. – Режим доступа: <https://arxiv.org/abs/1711.11585>

6. You Only Need Adversarial Supervision for Semantic Image Synthesis // Arxiv.org [Электронный ресурс]. – Режим доступа: <https://arxiv.org/abs/2012.04781>

© Д.В. Фисько, С.И. Сиротко, 2021